



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvdivieso@uc.cl) —

Clase 5: Visualizando Información Compleja

Contenidos

- Complejidad en la **privacidad** de datos
- Complejidad en el **tamaño** de los datos
 - ¿En qué consiste la reducción de dimensionalidad?
 - PCA y TSNE
 - Casos de aplicación de reducción de dimensionalidad

Privacidad de datos

Motivación

- A veces nos toca trabajar con datos que tienen información sensible para el usuario
 - Enfermedad.
 - Sueldo.
 - Deudas.
 - Entre otros (dependerá del contexto).
- 🤔 ¿Cómo aseguramos que no puedan identificar a nuestros usuarios?

Motivación

- Los datos se pueden catalogar en diferentes tipos (no excluyentes):
 - **Identificadores.** Información que permite identificar al individuo detrás de los datos; como el rut, mail uc, nombre completo.
 - **Potenciales identificadores.** Información general del individuo que eventualmente pueden servir para identificar al individuo; como la edad.
 - **No identificadores.** Información que por sí sola no permite identificar al individuo.
 - **Sensibles.** Información privada que se espera desvincular del individuo.

Name	Age	Glucose	Diabetes
Alice Smith	25	237	Yes
Bob Taylor	34	186	Yes
Frank Jones	33	165	Yes
Ivy Smith	42	80	No
Jim Davies	12	190	Yes
...	...	...	...

¿Qué podemos hacer con los datos?

- **Objetivo:** Asegurar que no sea posible vincular un dato sensible al usuario.
- **Acciones:**
 - Se evita mantener identificadores en la visualización.
 - **Intentar generalizar o modificar posibles identificadores.**

¿Qué podemos hacer con los datos?

- Se han creado diferentes técnicas para preservar la privacidad:
 - ***k-anonymity*** → Para cada fila, hay al menos ***K-1*** filas que tienen los mismos datos no identificadores o potenciales identificadores.
 - ***l-diversity*** → Para cada grupo de datos iguales, hay al menos ***L*** datos sensibles diferentes
 - ***t-closeness*** → Para cada grupo, la distancia entre la distribución de datos sensibles y la distribución de dichos datos en toda la tabla no supera el valor ***t***.

Veamos ejemplos de estas 2 técnicas.

¿Qué podemos hacer con los datos?

- ***k-anonymity*** → Para cada fila, hay al menos $k-1$ filas que tienen los mismos datos no identificadores o potenciales identificadores.

Company	Position	Nationality	Zip	Age	Disease
Alpha	Director	Japanese	10001	32	Galactosemia
Beta	Manager	Indian	11049	53	Cancer
Gamma	Associate	American	10011	38	Galactosemia
Beta	Manager	Russian	10004	43	Fatty Liver
Alpha	Manager	Japanese	10014	48	Hepatitis B
Delta	Consultan	Indian	10017	34	Galactosemia
Gamma	Associate	American	11042	57	Hepatitis B
Delta	Manager	American	10007	42	Hepatitis B
Gamma	Director	Japanese	11043	51	Galactosemia
Beta	Manager	Russian	10009	35	Galactosemia
Delta	Associate	Indian	10019	42	Fatty Liver
Gamma	Manager	Japanese	11047	63	Fatty Liver



Company	Position	Nationality	Zip	Age	Disease
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	110**	>=50	Galactosemia
*	*	*	110**	>=50	Cancer
*	*	*	110**	>=50	Hepatitis B
*	*	*	110**	>=50	Fatty Liver
*	*	*	100**	4*	Hepatitis B
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Hepatitis B

4-anonymity

Problemas con *k-anonymity*

- Si sé que Hernán tiene 38 años y vive en el código postal 10011, puedo descifrar fácilmente que tiene galactosemia (**ataque por homogeneidad**).

Company	Position	Nationality	Zip	Age	Disease
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	110**	>=50	Galactosemia
*	*	*	110**	>=50	Cancer
*	*	*	110**	>=50	Hepatitis B
*	*	*	110**	>=50	Fatty Liver
*	*	*	100**	4*	Hepatitis B
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Hepatitis B

Problemas con *k-anonymity*

- Si sé que Daniela tiene 49 años, trabaja en la compañía Delta, vive en 10019 y además sé que en dicha compañía están todos vacunados contra la hepatitis B, puedo deducir que Daniela tiene hígado graso (**ataque por información previa**).

Company	Position	Nationality	Zip	Age	Disease
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	100**	<40	Galactosemia
*	*	*	110**	>=50	Galactosemia
*	*	*	110**	>=50	Cancer
*	*	*	110**	>=50	Hepatitis B
*	*	*	110**	>=50	Fatty Liver
*	*	*	100**	4*	Hepatitis B
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Fatty Liver
*	*	*	100**	4*	Hepatitis B

Los dos problemas anteriores se abordan con *l-diversity*.

¿Qué podemos hacer con los datos?

- ***l-diversity*** → Para cada grupo de datos iguales, hay al menos L datos sensibles diferentes

Company	Position	Nationality	Zip	Age	Disease
Alpha	Director	Japanese	10001	32	Galactosemia
Beta	Manager	Indian	11049	53	Cancer
Gamma	Associate	American	10011	38	Galactosemia
Beta	Manager	Russian	10004	43	Fatty Liver
Alpha	Manager	Japanese	10014	48	Hepatitis B
Delta	Consultan	Indian	10017	34	Galactosemia
Gamma	Associate	American	11042	57	Hepatitis B
Delta	Manager	American	10007	42	Hepatitis B
Gamma	Director	Japanese	11043	51	Galactosemia
Beta	Manager	Russian	10009	35	Galactosemia
Delta	Associate	Indian	10019	42	Fatty Liver
Gamma	Manager	Japanese	11047	63	Fatty Liver



Company	Position	Nationality	Zip	Age	Disease
*	*	*	1000*	<50	Galactosemia
*	*	*	1000*	<50	Fatty Liver
*	*	*	1000*	<50	Hepatitis B
*	*	*	1000*	<50	Galactosemia
*	*	*	1104*	>=50	Hepatitis B
*	*	*	1104*	>=50	Galactosemia
*	*	*	1104*	>=50	Fatty Liver
*	*	*	1104*	>=50	Cancer
*	*	*	1001*	<50	Galactosemia
*	*	*	1001*	<50	Hepatitis B
*	*	*	1001*	<50	Galactosemia
*	*	*	1001*	<50	Fatty Liver

3-diversity

Métodos para intentar asegurar privacidad

- Generalización
- Filtrado
- Aplicar una máscara
- Reemplazar valores
 - Vecinos cercanos
 - Ruido



Métodos para intentar asegurar privacidad

- **Generalización**
- Filtrado
- Aplicar una máscara
- Reemplazar valores
 - Vecinos cercanos
 - Ruido

Edad	Edad Generalizada
11	< 50
69	>= 50
42	< 50
5	< 50
69	>= 50

Métodos para intentar asegurar privacidad

- Generalización
- **Filtrado**
- Aplicar una máscara
- Reemplazar valores
 - Vecinos cercanos
 - Ruido

Edad	Edad Filtrada
	69
69	42
42	69
	
69	

Métodos para intentar asegurar privacidad

- Generalización
- Filtrado
- **Aplicar una máscara**
- Reemplazar valores
 - Vecinos cercanos
 - Ruido

Edad	Edad con máscara
11	**
69	6&
41	4*
5	++
69	6&

Métodos para intentar asegurar privacidad

- Generalización
- Filtrado
- Aplicar una máscara
- Reemplazar valores
 - **Vecinos cercanos**
 - Ruido

Edad	Reemplazar Valores <i>Promedio Vecinos cercanos</i>
11 (cercano al 5)	8
69 (cercano al 68)	68,5
41	41
5 (cercano al 11)	8
68 (cercano al 69)	68,5

Métodos para intentar asegurar privacidad

- Generalización
- Filtrado
- Aplicar una máscara
- Reemplazar valores
 - Vecinos cercanos
 - **Ruido**

Edad	Reemplazar Valores Ruido
11	12
69	68
41	40
5	5
69	70

Decisiones en visualización para facilitar la privacidad



Hay casos donde no se puede modificar el *dataset* y es bueno pensar en formas que la visualización modifique *inline* la información antes de comenzar a dibujar.

Algunas decisiones implican:

1. Utilizar visualizaciones que dificultan la identificación total de un ítem.
2. Eliminación y/o agrupación de datos.
3. Aplicar ruido en función de vecinos cercanos o de forma probabilística.




Decisiones en visualización para facilitar la privacidad

Utilizar visualizaciones que dificultan la identificación total de un ítem.









Decisiones en visualización para facilitar la privacidad

Utilizar visualizaciones que dificulten la identificación total de un ítem.






Decisiones en visualización para facilitar la privacidad

Eliminación y/o agrupación de datos.




Decisiones en visualización para facilitar la privacidad

Eliminación y/o agrupación de datos.




Decisiones en visualización para facilitar la privacidad

Eliminación y/o agrupación de datos.




Decisiones en visualización para facilitar la privacidad

Eliminación y/o agrupación de datos.




Decisiones en visualización para facilitar la privacidad

Eliminación y/o agrupación de datos.




Decisiones en visualización para facilitar la privacidad

Aplicar ruido en función de vecinos cercanos o de forma probabilística.



Decisiones en visualización para facilitar la privacidad

Aplicar ruido en función de vecinos cercanos o de forma probabilística.



Decisiones en visualización para facilitar la privacidad

Algunas decisiones implican:

1. Utilizar visualizaciones que dificultan la identificación total de un ítem.
2. Eliminación y/o agrupación de datos.
3. Aplicar ruido en función de vecinos cercanos o de forma probabilística.

¿Cómo aplicamos estas decisiones? ¿cuándo? ¿Cuál es mejor? 🤔

→ Dependerá del contexto, cada caso es un mundo nuevo.

Decisiones en visualización para facilitar la privacidad

Se siguen haciendo esfuerzos para apoyar este proceso. Por ejemplo:




- Investigando la utilidad de diferentes formas de privatizar una visualización (2023)

Original

AHP

DAWA


Laplace



Decisiones en visualización para facilitar la privacidad

Se siguen haciendo esfuerzos para apoyar este proceso. Por ejemplo:


- Creando *software* que sugieren visualizaciones que muestran ciertos patrones (2022)




Reducción de dimensionalidad

Reducción de dimensionalidad

- Transformación de datos multidimensionales a datos de pocas dimensiones sin perder las caracterizaciones originales.
- Son un campo de estudio importante en *data science* y estadística.



Reducción de dimensionalidad



De 4.096 dimensiones
a 2 dimensiones

Reducción de dimensionalidad



🤔 ¿Cómo funcionan estas "dimensiones"?

- En conjunto, todas las nuevas dimensiones tratan de guardar la misma información que el ítem en su alta dimensionalidad.
- En algunos algoritmos, estas nuevas dimensiones se construyen a partir de combinar información de distintos atributos originales.

Reducción de dimensionalidad

🤔 ¿Cómo funcionan estas "dimensiones"?

- En algunos algoritmos, estas nuevas dimensiones se construyen a partir de combinar información de distintos atributos originales.




Reducción de dimensionalidad

🤔 ¿Cómo funcionan estas "dimensiones"?

- **Scree plot**

Indica cuanto es el porcentaje de *Explained variance* por cantidad de dimensiones que usemos.

Explained variance es la diferencia entre la varianza de los datos originales y la varianza de los datos generados con las N dimensiones.



Reducción de dimensionalidad

Algoritmos existentes:

- PCA
- LDA
- T-SNE
- Entre otros ...

En visualización se ocupan muchas veces para mostrar espacialmente y en dos dimensiones un *dataset*. De tal forma que ítems próximos realmente sean similares según sus todos sus atributos originales, y qué ítems lejanos sean realmente diferentes.

Reducción de dimensionalidad

Algoritmos existentes:



- **PCA**
- LDA
- **T-SNE**
- Entre otros ...

Vamos a entender la intuición de estos 2 algoritmos muy utilizados en la práctica.

Reducción de dimensionalidad

PCA



- Busca describir la ubicación de cada punto como una **combinación lineal de los pesos de cada eje**.
- El algoritmo debe encontrar los ejes, desde el que captura más varianza en adelante



Reducción de dimensionalidad

PCA - Ventaja


- Una vez aprendido los ejes, puede posicionar un nuevo dato en alta dimensión a baja dimensión.
- Intuitivo de entender dado que un eje es solo la combinación de atributos originales. Esto ayuda a entender cuáles atributos son los que más variación tienen.
- La ejecución es determinista y solo es un conjunto de operaciones.



Reducción de dimensionalidad

PCA - Desventajas



- Para preservar la varianza, datos alejados en alta dimensión, intenta que estén alejados en baja dimensión.
- 🤔 ¿Cuál distancia consideramos aquí?
- En determinados escenarios, el no poder considerar otro tipo de combinaciones supone perder mucha información



Reducción de dimensionalidad

PCA - Desventajas II


- Muy influenciado por datos atípicos. Estos alteran fácilmente la varianza de datos.
- No siempre reducir la dimensionalidad implica hacer combinaciones lineales de los atributos



Reducción de dimensionalidad

TSNE: *T-distributed Stochastic Neighbor Embedding*


- Reducción de Dimensionalidad No Lineal → No se hacen combinaciones de atributos.
- Algoritmo iterativo que paso a paso va ajustando los datos a la baja dimensión.



Reducción de dimensionalidad

TSNE - Calculo


1. Mide la distancia de los puntos en alta dimensión (p_{ij})



Reducción de dimensionalidad

TSNE - Calculo

1. Mide la distancia de los puntos en alta dimensión (p_{ij})
2. Posiciona los datos al azar y mide distancia en baja dimensión (q_{ij})



Reducción de dimensionalidad

TSNE - Calculo

1. Mide la distancia de los puntos en alta dimensión (p_{ij})
2. Posiciona los datos al azar y mide distancia en baja dimensión (q_{ij})
3. Actualiza los pesos en baja dimensión apoyándose de esta fórmula

$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$$

Penalizamos los casos en que la distancia es grande en el espacio de alta dimensión (p_{ij}) y es baja en el espacio de baja dimensión (q_{ij}).

→ **No acerquemos puntos que estaban lejos antes.**


→ Le da lo mismo si un punto que estaba cerca antes, ahora queda lejos.

Reducción de dimensionalidad

TSNE - Calculo


Forma más visual

Stage 1




Stage 2


a. Randomly project cells as points on a low-dimensional plot



b. Determine similarities between points





c. Move the points around until the similarities between points in low dimension resemble the similarities in high dimensions



Reducción de dimensionalidad

TSNE - Calculo

Forma más visual





*gif

Reducción de dimensionalidad

TSNE - Ventaja

- Abre la puerta a crear nuevas dimensiones que no se pueden representar como combinación lineal de las ya existentes.
- Los datos atípicos no le afectan.
- Mas sensible a datos similares.



Reducción de dimensionalidad


TSNE - Desventaja

- Las nuevas dimensiones no se pueden mapear fácilmente a las originales.
- La baja interpretación de su algoritmo (*black box*), es decir, permite visualizar muy bien datos, pero no genera, por ejemplo, una serie de ecuaciones fácilmente interpretables como hace el PCA.
- No es un proceso determinista, por lo que, a pesar de emplear los mismos datos, los resultados pueden variar.
- Si llegan nuevos datos, hay que ejecutar todo de nuevo.

Reducción de dimensionalidad

TSNE - Desventaja

- Dependerá de los hiper-parámetros que nosotros definamos previamente
 - *Perplexity*: forma de medir el efecto que tendrán los vecinos de cada punto.



Original



Perplexity: 2
Step: 5,000



Perplexity: 5
Step: 5,000



Perplexity: 30
Step: 5,000



Perplexity: 50
Step: 5,000




Perplexity: 100
Step: 5,000

Reducción de dimensionalidad - Casos de aplicación

Cantantes similares


- Cada cantante se representa con información de sus canciones.
- Se construye un vector (x, y) por cantante mediante reducción de dimensionalidad.



Reducción de dimensionalidad - Casos de aplicación

Visualización de *Embeddings*


- ¿Qué es *embeddings*? Representación numérica de algún elemento (texto, imagen, dato tabular, etc.)
- Se construye un vector (x, y, z) por *embedding* para identificar elementos "similares".



Reducción de dimensionalidad - Casos de aplicación

Comparación visual de técnicas



- Cada punto es una imagen de un número (0 al 9) cuyo color indica su clase.
- La posición se determina según el vector de *feature* que se obtiene del modelo de DL (LeNet) y con reducción TSNE.
- Se probaron diferentes técnicas de clasificación (*SingleTask*, *Multitask* tradicional y *Multitaks* con pérdidas ponderadas) y entrenando con diferente cantidad de épocas.



Reducción de dimensionalidad - Casos de aplicación

Comparación visual de efectividad de *datasets*


- Cada punto es una imagen de un tifón cuyo color es su categoría (potencial del tifón).
- La posición se determina según el vector de *feature* que se obtiene del modelo de DL (VGG-16) y con reducción TSNE.
- Se probó el mismo modelo pero usando el *dataset* original vs uno preprocesado.



● Normal ● Strong ● Very Strong ● Violent

Reducción de dimensionalidad

En términos del *Framework* de Tamara Munzner...



Derivamos nuevos datos

Identificamos clusters

Definir un nombre



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvdivieso@uc.cl) —
