



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvdivieso@uc.cl) —

Clase 6: Visualizaciones con Matplotlib/Seaborn

Contenidos

- Visualizaciones tabulares con Matplotlib/Seaborn
 - Comparación y Tendencia
 - Correlaciones
 - Distribuciones
 - Múltiples gráficos

Presentación de diversos gráficos

Presentación de diversos gráficos

- Veremos un compilado de gráficos en donde se entregará:
 - Una descripción del gráfico.
 - En qué situaciones se utilizan generalmente.
 - Código para programarlo con Pandas, Matplotlib y/o Seaborn.
- Catálogo 100% recomendado: [Data Viz Project](#)
- Códigos para confeccionar estas visualizaciones se encuentran en: [\[MIA\] Clase 6 - Visualizaciones Tabulares Matplotlib-Seaborn](#)
- Datos: [Heart Failure Prediction Dataset](#)

Presentación de diversos gráficos

Comparación y tendencias
Gráfico de barra y línea

Gráfico de barras

- Utilizado para representar un atributo **categorico** y otro **numérico**.
- Uno de los ejes muestran los datos **categoricos**.
- El otro muestran los datos **cuantitativos**.
- Gráfico muy efectivo para hacer **comparaciones**.
- El orden del eje categorico es una de las decisiones más relevantes: aleatorio, alfabético, orden según valor numérico, orden según semántica para datos ordenados.





Gráfico de barras (*Silhouette Score*)

- Utilizado para evaluar la calidad de *clustering*.
- Se mide la similitud de cada punto de datos con el *cluster* al que pertenece y su diferencia con otros *clusters*





Gráfico de línea

- Utilizados para presentar **tendencias**
- En el eje **X** se pone una variable **ordenada** (típicamente datos temporales)
- En el eje **X** puede perfectamente ponerse **cientos de niveles** (valores) y el gráfico escala bien visualmente




Gráfico de línea (ROC Curve)

- Dado un modelo que predice con cierta probabilidad y un resultado binario. Se determinan diferentes umbrales de probabilidad para ver cómo clasifica el modelo.
- *True Positive Rate*: El modelo predice correctamente que algo es positivo, dividido el total de datos que son positivos.
- *False Positive Rate*: El modelo predice positivamente algo que en realidad es negativo, dividido el total de datos negativos.




Gráfico de línea

- El uso de línea provoca una interpretación de orden en los puntos. Por este motivo, un gráfico de línea **debe presentar un eje X ordenable**







Gráfico de línea (*Elbow Curve*)

- Técnica que se utiliza para determinar el número óptimo de *clusters*.
- Se calcula la suma de las distancias al cuadrado entre cada punto de datos y su centroide asignado para diferentes valores de k .
- Se busca donde la línea ya no presenta una pendiente tan pronunciado.

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$






Gráfico de línea (*Silhouette Score*)

- Esta métrica también se puede usar como técnica para determinar el número óptimo de *clusters*.
- Para diferente número de *clusters* se calcula el *silhouette score* promedio.
- Se busca el punto más alto.
- Se puede utilizar para contrastar varios modelos de *clustering* simultáneamente.



Código en Python

Vamos al código  

Presentación de diversos gráficos

Correlaciones

Gráfico de dispersión y de burbuja

Gráfico de dispersión

- En inglés se conoce como **scatterplot**.
- Utilizado para visualizar **relaciones entre dos atributos cuantitativos**.
- Permite visualizar fácilmente si es que existe **correlación**, tanto positiva como negativa.
- Se usa el canal de posición horizontal y vertical (X,Y) para transmitir la información de los 2 atributos cuantitativos.







Gráfico de dispersión (ejemplos)

- Muestra una correlación **positiva**
- Ilustra que **no hay relación** entre las variables X e Y





Gráfico de burbuja

- **Extensión** del gráfico de dispersión.
- Permite codificar **más atributos** usando el **color** y el **tamaño** de los puntos.
- El tamaño del círculo se utiliza para atributos **ordenados**
- El color puede usarse para atributos **categoricos u ordenados** dependiendo de la paleta de colores utilizada.





Gráfico de burbuja (ejemplo)



*gif

Código en Python

Vamos al código  


Presentación de diversos gráficos

Distribuciones

Histograma, gráfico de caja, violín,
de torta y mapa de calor

Histograma

- El término histograma fue acuñado en 1891 por el matemático y estadístico Karl Pearson.
- Gráfico muy usado en **estadística**, especialmente análisis de datos exploratorio.
- Permite conocer la **distribución** de los valores de un atributo numérico, su rango y **frecuencia** de un atributo categórico.
- Ejemplo: la distribución del *error* entre 3 modelos distintos.



Histograma

- Permite identificar rápidamente los valores **más comunes** (Ej.: edad más común).
- También permite identificar valores menos comunes y datos extraños (**outliers**).
- Similar a un gráfico de barras, pero diferente en cuanto a la **obtención de datos**.
- Las cantidad de barras, en lugar de corresponder a categorías fijas, corresponden a **rangos de valores** calculados automáticamente.




Gráfico de caja

- En inglés se denomina **box plot**.
- Permite visualizar la **distribución de datos de una variable numérica** (cuantitativa continua), enfatizando medidas estadísticas como la mediana, cuartiles y *outliers*.
- La caja central está delimitada por el cuartil Q1 (percentil 25) y el cuartil Q3 (percentil 75). La línea dentro de la caja indica la mediana (percentil 50).




Gráfico de caja

- Se puede utilizar una marca adicional (un asterisco, por ejemplo) para representar el **promedio**.
- Se agregan dos líneas adicionales fuera de la caja que indican unos **límites mínimos y máximos esperados**, equivalentes a:
 - $min = Q1 - 1,5 \times IQR$
 - $max = Q3 + 1,5 \times IQR$
 - IQR significa "rango intercuartil" = $Q3 - Q1$.
- Fuera de los límites mínimo y máximo, se encuentran los "outliers".




Gráfico de caja




Gráfico de caja (ejemplo)

- Permite comparar fácilmente la distribución de valores de *accuracy* entre diferentes modelos para una tarea de *Machine Learning*.




Gráfico de violín

- Combinación del gráfico de un gráfico de densidad y un gráfico de caja
- Permite visualizar **distribución estadística y densidad** de un atributo numérico.
- *Paper* donde fue propuesto: [Violin Plots: A Box Plot-Density Trace Synergism](#)




Gráfico de violín (ejemplo)

2018 daily avg temperatures by month (°F)






Gráfico de violín vs Gráfico de Caja



*gif

Gráfico de torta

- Se utiliza una disposición circular para visualizar los datos, y se utiliza el **ángulo** para codificar la información. A mayor ángulo, el área es mayor y se entiende que el valor es más grande.
- Se utiliza principalmente para mostrar **proporciones** dentro de un total



Datos			
Piedra	Papel	Tijeras	TOTAL
2	3	4	9
Para calcular porcentajes			
$2/9=22\%$	$3/9=33\%$	$4/9=44\%$	100%
Grados para cada «porción de tarta»			
$(2/9) \times 360 = 80^\circ$	$(3/9) \times 360 = 120^\circ$	$(4/9) \times 360 = 160^\circ$	360°

Gráfico de torta (mini debate)




Gráfico de torta (mal ejemplo)

- Asegurar que siempre sea para visualizar una parte del total, es decir que los porcentajes suman 100%.
- No poner tantas categorías.







Gráfico de torta (buen ejemplo)

- Podrían existir situaciones exitosas con este gráfico.
- Por ejemplo, cuando son pocas categorías o para complementar otra visualización.




Mapa de calor


- Cada celda de la matriz codifica un **tercer atributo**.
- Este tercer atributo debe ser cuantitativo secuencial o divergente.
- Permite ver la distribución del tercer atributo a lo largo de las combinaciones de las filas y columnas.
- Eficiente en espacio.

How Popular Is Your Birthday?


Two decades of American birthdays, averaged by month and day.



Mapa de calor (ejemplo)



Percentage of men's English league games ending in a given score, for tiers 1-4, 1888 through 2013-14 season



Código en Python

Vamos al código  


Presentación de diversos gráficos

Múltiples gráficos

Matriz de gráfico y pequeños
múltiples


Matriz de gráficos

- Cada celda de la matriz es otra codificación por sí sola.
- Cada codificación no necesariamente debe ser la misma.
- *Datasets* con múltiples atributos suelen ser compatibles.
- Forma eficiente de mostrar la relación entre variadas combinaciones de atributos.



Matriz de *scatterplots*


- Un caso común de matriz de gráficos.
- Un *scatterplot* permite apreciar una posible relación entre dos atributos cuantitativos.
- Un *dataset* con más de dos atributos cuantitativos es muy compatible con esta codificación.
- En la diagonal a veces se incluye otro tipo de visualización



Pequeños múltiples o *Small Multiples*


- Un caso **particular** de matriz de gráficos.
- Cada celda presenta la **misma codificación**.
- Todos los gráficos comparten los **mismos atributos**.
- Cada gráfico posee sólo **1 categoría** posible respecto al atributo definido.
- Utilizado comúnmente cuando hay un atributo con **demasiadas categorías**.

day	calories	student
1	1403	a
5	1378	b
6	1422	b
10	1422	b
6	1379	c




Pequeños múltiples o *Small Multiples*

A spaghetti chart of baby names popularity



Popularity of American names in the previous 30 years



Pequeños múltiples o *Small Multiples*

¿Donde nacieron los jugadores estadounidense de las grandes ligas de *Baseball*?



Código en Python

Vamos al código  



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvdivieso@uc.cl) —
