



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvdivieso@uc.cl) —

Clase 7: Visualización en otros dominios

Contenidos


- Visualización de datos de red.
- Visualización de datos espaciales (geográficos y campos espaciales).
 - Proyección cartográfica.
 - Visualizaciones y casos aplicados.
- Visualización de texto.
 - Procesamientos y casos aplicados de visualización de texto.

Visualización de datos de red

Dataset de red

- Representar situaciones donde existen relaciones entre dos o más ítems.
- Compuestos por datos de tipo ítem (nodos) y de tipo enlace.
- Algunos ejemplos típicos son redes sociales, red de tráfico, árbol jerárquico de una empresa, entre otros.

→ Networks




→ Trees



Dataset de red



- Se pueden aplicar en diferentes contextos.



Dataset de red

Hay redes dirigidas y no dirigidas.

- **Dirigidas:** útil para representar relaciones asimétricas. Por ejemplo:
 - Jefaturas: Sofía es la jefa de María en la empresa.
 - Seguir a un usuario en redes sociales: Hernán siguió a Nicolas en Instagram y Twitter.
- **No dirigidas:** útil para representar relaciones simétricas. Por ejemplo:
 - Amistades de Facebook: Si Hernán es amigo de Nicolás, Nicolás también será amigo de Hernán.




Dataset de red

Los nodos y/o enlaces pueden contener atributos.

SHAKESPEAREAN TRAGEDY



TITUS ANDRONICUS
Number of characters 36 | 50% Network density




HAMLET
Number of characters 37 | 39% Network density



KING LEAR
Number of characters 33 | 45% Network density

Dataset de red

Pueden ser del tipo jerárquico




Dataset de red - Métricas

- En este tipo de dataset existen diferentes métricas, generalmente numéricas, que entregan una pequeña descripción de la red o nodos.
 - **De la red:** cantidad de nodos, cantidad de enlaces, diámetro (distancia máxima entre nodos de una red) y distancia promedio entre nodos
 - **De cada nodo:** grado (cantidad de conexiones) y cercanía (distancia promedio con otros nodos)
- Si están interesados en profundizar sobre medidas en redes, pueden revisar el siguiente enlace: [4. Measuring Networks Part 1: Centrality and Global Measures](#)

Dataset de red - Métricas

- Cantidad de nodos: 24
- Cantidad de enlaces: 106
- Diámetro (distancia máxima entre nodos de una red): 4
- Distancia promedio entre nodos: 2.23




Dataset de red - Métricas

Nodo Gandalf

- Grado: 16
- Cercanía: 1.30


Name	Gandalf
Degree	16
Betweenness Centrality	27.9
Closeness Centrality	1.30
Eigenvector Centrality	0
Triangles	68
Eccentricity	2
Group	1
Pagerank	0.10



Nodo Saruman

- Grado: 7
- Cercanía: 1.74

Name	Saruman
Degree	7
Betweenness Centrality	22.7
Closeness Centrality	1.74
Eigenvector Centrality	0
Triangles	12
Eccentricity	3
Group	2
Pagerank	0.031



Dataset de red - Visualización

Algunos objetivos dentro de estos datos que motivan a realizar visualizaciones son:

- **Los caminos entre nodos.**
 - Conocer la distancia entre nodos específicos.
 - Conocer si están conectados directamente.
 - Conocer qué nodos hay en el camino.
- **La topología**, que es la forma general de la red, cómo se interconectan sus nodos: de forma tanto directa como indirecta.
 - Hay algún nodo que conecta con todos.
 - Hay *clusters* de nodos.
 - Hay nodos sin ninguna conexión.

Dataset de red - Visualización

Existen muchas formas de visualizar estos datos.

- [Graph Visualization](#)
[Introduction / Brian Staats /](#)
[Observable](#)

En esta clase abordaremos 3 formas principales de visualizar:

- Nodo-enlace.
- Matriz de adyacencia.
- *Idioms* de contención.

6 WAYS TO VISUALIZE



ROBERT GOVE • TWO SIX LABS


FORCE
DIRECTED




GROUP IN A BOX




RADIAL




SEMANTIC
SUBSTRATE



ARC
DIAGRAM



MATRIX DIAGRAM




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

- También conocido como **grafo**.
- **Nodos (puntos o áreas)**: tamaño, color, y posición.
- **Enlaces (líneas o áreas)**: ancho, color y tipo de línea. También puede incluir una **flecha** (en lugar de línea) para identificar tipos de relaciones.




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

Gráfico ideal para entender la **topología** de la red.

- Encontrar todos los caminos usando conexiones de la red entre dos nodos específicos.
- Encontrar el camino más corto entre dos nodos.
- Encontrar todos los nodos directamente adyacentes a un nodo específico.
- Encontrar nodos importantes dentro de la red en términos de conectividad.






Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

Una de las tareas más difíciles es intentar que el grafo se vea lo "más entendible posible".

- No se superpongan los nodos.
- Evitar la intercepción de líneas.






Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

🤔 ¿Cómo determinar la posición de los nodos?

- Existen gráficos del tipo nodo-enlace que fijan las posiciones de los nodos. Aunque su implementación es difícil de realizar.
 - **Diagrama de Arco** - Utiliza un eje (X o Y) para posicionar todos los nodos.
 - **Diagrama de Cuerdas Sin Cinta** - Utiliza una disposición radial para posicionar los nodos.
 - **Hive plot** - Genera múltiples ejes.





Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

🤔 ¿Cómo determinar la posición de los nodos?

- Simular fuerzas físicas como si fueran partículas.
- Los enlaces provocarán, en la simulación, que 2 nodos se intenten juntar, mientras que la ausencia de estos permitirá que se alejen los nodos.
- Esta técnica hace que la posición ya no codifique ninguna información.
- Más fácil de implementar y barata computacionalmente que los otros enfoques.




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - Red de sabores

- Cada nodo denota un ingrediente.
- El color del nodo indica la categoría de alimentos.
- El tamaño del nodo codifica la cantidad de recetas que usan dicho ingrediente.
- Dos ingredientes están conectados si comparten un número significativo de compuestos de sabor.
- El grosor del enlace representa el número de compuestos compartidos entre los dos ingredientes.


Flavor Network

Yong-Yeol Ahn, Sebastian Ahnert, James P. Bagrow, and A.-L. Barabási



Flavor network. Culinary ingredients (nodes) and their chemical relationship are illustrated. The color of each ingredient represents the food category that the ingredients belong to, and the size of an ingredient is proportional to the frequency we use (collected from online recipe databases) experience on, also (specimen, ingredients). Two culinary ingredients are connected if they share more flavor compounds. We extracted the list of flavor compounds in each ingredient from the food "chemically breakdown" of flavor ingredients (left) and then applied a backbone extraction method by Serres et al. (2015) and apply to pick statistically significant links between ingredients. The thickness of an edge represents the number of shared flavor compounds. To reduce clutter, edges are bundled based on the algorithm by Dorner (2010) (<http://www.cse.cmu.edu/~dorner/>).

Nodo-enlace y Matriz de Adyacencia




Nodo-enlace - Animes vistos

- Cada nodo es una serie.
- El tamaño del nodo codifica la cantidad de personas que ven esa serie.
- Dos series están conectadas si hay muchas personas que vieron ambas series.
- El grosor del enlace representa el número de personas que vieron ambas series.

Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - 2D Visualization CNN


- Cada nodo es una unidad del filtro de una capa o bien una unidad de una capa *fully connected*
- Los enlaces unen un nodo con los pesos utilizados de la capa anterior
- El color del enlace representa el valor del nodo de la capa anterior.



Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - Conexiones cables submarinos




- También se puede ver como un mapa de flujo.
- Los enlaces unen el inicio y fin de un cable submarino.



Nodo-enlace y Matriz de Adyacencia

Nodo-enlace




- **Ventaja:** Intuitivo para el humano de entender
- **Desventaja:** la escalabilidad. Si hay **más de 4 veces** enlaces que nodos, o son miles de nodos, pueden generarse bolas de pelos y se recomienda utilizar otro *idiom*.



Nodo-enlace y Matriz de Adyacencia



Matriz de Adyacencia

- Disposición de los nodos en los bordes de una matriz. Cada celda pintada indica la presencia de una conexión.
- Suele ir bien con redes grandes aunque es menos intuitiva de entender que el diagrama Nodo-enlace.



Nodo-enlace y Matriz de Adyacencia

Matriz de Adyacencia



Nodo-enlace y Matriz de Adyacencia

Matriz de Adyacencia

Algunas tareas eficientes son:


- Estimación del número de nodos → Tamaño de la matriz
- Estimación del número de enlaces. → Cantidad de celdas pintadas
- Encontrar los nodos más conectados. → Filas/columnas muy pintada
- Encontrar un nodo según etiqueta. → Explorar nombres de fila/columna
- Encontrar un enlace entre un par de nodos. → Intercepción entre fila/columna

Jerarquías y Árboles

Jerarquías y Árboles

Caso particulares de red donde **no existen ciclos** en sus conexiones.

- Dado un nodo X, no existe un camino que parta en dicho nodo y termina en el mismo nodo pasando solo 1 vez por cada conexión del camino.





En este tipo de red, hay 4 conceptos importantes:

1. **Nodo hijo:** es el nodo receptor de una conexión. B es hijo de A, D es hijo de C.
2. **Nodo padre:** es el nodo de donde sale una conexión. A es padre de C, C es padre de E.
3. **Nodo hoja:** son los nodos que no tienen hijos. B, D y E son nodos hojas.
4. **Nodo raíz:** es el nodo que no tiene padre. A es nodo raíz.



Jerarquías y Árboles

- Este tipo de dato se conoce como **árbol** o **de jerarquía**.
- Si bien podemos usar los gráficos nodo-enlace o matriz de adyacencia para codificar un árbol. El hecho de que exista un orden (la jerarquía) **las posibilidades de estos gráficos cambian y aumentan**.



Jerarquías y Árboles



Es común recurrir al uso de **contención espacial** para comunicar jerarquía.



Jerarquías y Árboles

Treemap


- Cada área representa un nodo.
- El tamaño **puede** codificar algún atributo numérico. Este canal se aplica a nodos hojas y el tamaño de los demás nodos se obtiene a partir de la suma de sus hijos.
 - Permite apreciar las contribuciones de distintas secciones de la jerarquía dentro de la totalidad de la red.
- El color **puede** codificar un atributo categórico.



Jerarquías y Árboles

Treemap

- Eficientes en espacio y buenos para hacer notar valores anormales para el atributo codificado.
- Ineficientes para tareas relacionadas a la topología de la red.




Treemap



Jerarquías y Árboles

Circle packing








- Versión circular del *Treemap*.
- En muchos casos es más fácil de leer e interpretar que el *Treemap*.
- Uso del espacio menos eficiente, y para jerarquías grandes el espacio necesario puede ser muy grande para apreciar detalles.



Jerarquías y Árboles

¡Existen muchas opciones más!

Es nuestro trabajo evaluar cuál diseño es el adecuado para nuestros datos y tareas.



Resumen de conceptos importantes

- **Red (*network*):** tipo de *dataset* donde tenemos ítems (nodos en este caso) y conexiones/relaciones entre ítems (enlaces en este caso).
- **Grafo:** visualización donde cada nodo se representa con un área (generalmente círculo) y se usan líneas para representar la conexión.
- **Diagrama nodo-enlace:** otro nombre para un grafo.
- **Árbol:** tipo particular de red donde no hay ciclos en las conexiones.

(Anexo) Redes y Python



- Una librería muy popular para analizar y dibujar grafos es [NetworkX](#)
 - Permite calcular métricas dado un grafo y crear visualizaciones estáticas.
 - Permite seleccionar diferentes algoritmos para posicionar los nodos.
 - Dibuja el grafo utilizando Matplotlib por debajo.
 - [Tutorial](#) y [Galería](#)
- Otra librería conocida es [pyvis](#)
 - Genera visualizaciones interactivas de grafos.
 - Utiliza código JS y HTML por detrás para permitir la interactividad.
 - [Tutorial](#)
- Bonus: [Demo Networkx y pyvis](#)

Visualización de datos espaciales

Proyección Cartográfica




Proyección cartográfica

- Mapeo de posiciones en el globo (esfera) a posiciones en la pantalla (superficie plana).
- Software gratuito **G Projector** de la NASA. Explora una gran variedad de estas proyecciones.




¿Por qué ver proyecciones?

Pasar de 3D a 2D no se logra del todo. **Se debe ceder** en algún punto.



Proyección de Mercator (1569) - Conforme

Diseñada para facilitar el **trazado de rutas** en la superficie terrestre dado que mantiene ángulos (deformación conforme).



Las superficies se **deforman** según se aproximan a **latitudes polares**.




Proyección de Peters (1855) - Equivalente


Al contrario de la proyección de Mercator, esta proyección se asegura de **mantener las áreas** (deformación equivalente).



A costa de mantener la proporción de áreas, se **distorsiona la forma** real de los países.



Y hay muuuchas más



Lista de proyecciones

Links de interes

- [The True Size Of ...](#)
- <https://engaging-data.com/country-centered-map-projections/?c=152>
- [Google Map ocupa una variante de Mercator \(Web Mercator\)](#)


Visualización de datos espaciales

Visualizaciones y casos
aplicados

Visualización de datos geoespaciales

Mapa de puntos


- Visualizan fenómenos puntuales colocando un símbolo o píxel donde se produce el fenómeno.
- Se usan círculos, barras, cuadrados, etc. El valor está codificado por tamaño o color.



Visualización de datos geoespaciales

Mapa de puntos


- **Ventaja:** gran facilidad de comprensión e ilustran la variación de una cierta densidad espacial.
- **Desventaja:** la superposición de puntos dificulta comparar zonas con alta densidad de eventos.



Visualización de datos geoespaciales

Cluster map


- Agrupa todos los puntos que estén a cierta distancia entre ellos. El tamaño del círculo puede ser en función de la cantidad de puntos o de algún otro atributo
- **Ventaja:** Permite identificar zonas de altas concentraciones donde los puntos se podrían superponer.
- **Desventaja:** Requiere realizar *zoom* si deseamos ver alguna ubicación puntual de los datos.



Visualización de datos geoespaciales

Heatmaps


- Superpone un mapa de calor sobre el mapa geográfico. El color puede representar la densidad de puntos en dicha zona o algún otro atributo.
- **Ventaja:** Permite identificar zonas de altas concentraciones de puntos de un atributo. El uso de color destaca más que el uso de área.
- **Desventaja:** Comparar la información entre 2 zonas se vuelve más difícil.



Visualización de datos geoespaciales

Choropleth map


- Muestra áreas geográficas divididas o regiones coloreadas en relación con una variable numérica. Se requiere disponer de las divisiones.
- **Ventaja:** Permite estudiar cómo evoluciona una variable a lo largo de un territorio.
- **Desventaja:** Las regiones con tamaños más grandes tienden a tener un mayor peso en la interpretación del mapa, que incluye un sesgo.



Visualización de datos geoespaciales

Cartograma


- Tipo específico de transformación de mapa, donde las regiones se redimensionan de acuerdo con una variable.
- Las regiones se colorean de acuerdo con otro atributo numérico o categórico.
- **Ventaja:** Evitan el problema de los mapas coropléticos a través de la distorsión no controlada.
- **Desventaja:** Distorsiona los límites reales y, por lo tanto, hace que el mapa sea más difícil de identificar





Visualización de datos geoespaciales

GridMap

- Se asigna una celda de igual tamaño para cada región.
- Ya no hay distorsión en el mapa como lo haría un cartograma o áreas de diferentes tamaños como el mapa de coropletas.



*gif



COUNTRIES WITH THE MOST PAID VACATION DAYS


Resume.io reviewed the annual statutory paid leave and paid public holidays laws in 197 countries, referring to government websites, the OECD, the International Labour Organization, etc. They then ranked the countries based on the combined number of statutory paid leave days and paid public holidays per year.

Paid leave refers to the statutory minimum annual time off bookable by the individual. Vacation days refers to the combined total of paid leave days and paid public holidays.

Top 10 Countries by Total Paid Vacation

Iran	53
Yemen	45
Bahrain	44
Bhutan	44
Madagascar	43
Niger	43
Togo	43
Azerbaijan	42
Kuwait	42
Mali	42

DATA SOURCE: [Resume.io](https://resume.io)



Note:
The tile/grid map mostly manages to keep nice recognisable countries shapes. But it's neither a true tile map nor a true geographical filled map.

Resultar Country

Hover over a square to learn more

9


53

DESIGNED BY: AAKARSH R | [@aakarsh_r6](https://twitter.com/aakarsh_r6)

Visualización de datos geoespaciales

Mapa Hexagonal


- Igual que un mapa de grilla, pero usando otra forma (hexágonos en este caso).



Visualización de datos geoespaciales


Mapa de flujo

- Muestran movimientos lineales. Se usan líneas en forma de flecha indicando dirección y sentido del flujo.
- El uso de línea permite representar el tipo de movimiento que se da y la cantidad de movimiento que se está dando.
- El ancho de las líneas generalmente codifica la cantidad de movimiento.



Ejemplo aplicado: Transporte público

Visualización espacio-temporal de uso de estaciones de metro, comparando tráfico 11 am versus 6 pm.



Visualización de texto

Procesamientos y casos
aplicados de visualización de
texto.

Visualización de texto

¿Por qué estudiar visualizaciones de texto?

- Porque son datos no estructurados así que no se aplica directamente todo lo que hemos vistos.
- Porque es uno de los tipos de datos más comunes.
- Porque visualizar texto nos puede dar muchos "*insights*".
- Porque es bueno saber qué tipo de "modificaciones" pudo sufrir el texto antes de ser visualizado

Visualización de texto

¿Por qué estudiar visualizaciones de texto?

	Atrib. 1	Atrib.2	Atrib. 3	Atrib. 4	Atrib. 5	Atrib. 6	Atrib. 7	Atrib. 8
Obj. 1	0	0	1	2	7	0	1	0
Obj. 2	1	1	5	8	0	0	1	0
Obj. 3	1	1	0	0	5	9	3	1
Obj. 4	3	7	3	6	3	8	2	2


1. Loomings	
Call me Ishmael. Some years ago—never mind how long precisely—having little or no money in my purse, and nothing particular to attract the eye on shore, I thought I would sail about a little and see the watery part of the world. It is a way that I cannot describe to you. I am not a seaman. I have never been to sea before, and never will, unless I find myself irrationally gazing before me at the water. I am not a seaman. I have never been to sea before, and never will, unless I find myself irrationally gazing before me at the water. I am not a seaman. I have never been to sea before, and never will, unless I find myself irrationally gazing before me at the water.	will content them but the enormous limit of the land, looking under the shady lee of land. Look at the crowd of slender waitresses will not reflect. No. They must get just as right the water as they possibly can without falling in, and there they stand—motionless—like statues. Islanders all, they come from lanes and alleys, streets, and avenues—north, east, south and west. Yet here they all enter. Tell me, does the magnetic virtue of the needles of the compasses of all these ships attract them thither? Once more: See you are in the country; in some high land of lakes. Take almost any path you please, and in no time it carries you down to a delta, and leaves you there by a pool in the stream. There is magic in it. Let the most absent-minded of men be plunged in his deepest reverie—stand that man on his legs, set his feet a-going, and he will infallibly lead you to water; if water there be in all that region. Should you ever be asked in the great American

Visualización de texto

¿Cómo estructuramos un poco el texto?

Representamos un documento como una **bolsa de palabras**, sin considerar el orden de éstas

Un tomate rojo y un globo rojo



Visualización de texto

¿Cómo estructuramos un poco el texto?

Podemos representar la bolsa de palabras de forma numérica, en una matriz

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc 1	0	1	0	0	1	0	1	0	0
Doc 2	0	0	1	0	2	1	2	0	1
Doc 3	1	0	0	1	0	1	2	1	1

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y

Visualización de texto

Pre-procesamiento típicos en el texto

- Normalizar (pasar todo a minúsculas, todo mayúsculas).
- Eliminación de *stop-words* (eliminar ciertas palabras).
- Stemming o Lematización (llevar un conjunto de palabras distintas a una igual).
- N-grams (separar la frase en conjuntos de N palabras).
- TF-IDF para no utilizar frecuencias.

Visualización de texto

Stopword

- Consiste en **eliminar del documento palabras muy comunes** que no aportan información.
- Estas palabras ocurren en casi todos los documentos, y puede ser preferible eliminarlas.

Sample text with Stop Words	Without Stop Words
GeeksforGeeks – A Computer Science Portal for Geeks	GeeksforGeeks , Computer Science, Portal ,Geeks
Can listening be exhausting?	Listening, Exhausting
I like reading, so I read	Like, Reading, read

Visualización de texto

Stemming

- Conservamos la raíz (literal) de la palabra
- Cambio, cambios, cambió, cambiando, cambiado → **Cambi**

Lematización

- Hacer una reducción apropiada a una palabra raíz (más inteligente).
- Soy, es, eres, somos, son → **SER**

Visualización de texto

N-gramas

• $N = 1$: Esta es una oracion unigramas

- Esta,
- es,
- una,
- oracion

• $N = 2$: Esta es una oracion bigramas

- Esta es,
- es una,
- una oracion

• $N = 3$: Esta es una oracion trigramas

- Esta es una,
- Es una oracion

Visualización de texto

TF-IDF

- TF : *Term Frequency* : Número de veces que está la palabra
- DF : *Document Frequency* : Número de documentos que tiene la palabra

Calculamos **TF * 1/DF**

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc 1	0	1	0	0	1	0	1	0	0
Doc 2	0	0	1	0	2	1	2	0	1
Doc 3	1	0	0	1	0	1	2	1	1

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y

Visualización de texto

TF-IDF

- TF : *Term Frequency* : Número de veces que está la palabra
- DF : *Document Frequency* : Número de documentos que tiene la palabra

Calculamos **TF * 1/DF**

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.


Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc 1	0	1 (1)	0	0	0.5 (1)	0	0.33 (1)	0	0
Doc 2	0	0	1 (1)	0	1 (2)	0.5 (1)	0.66 (2)	0	0.5 (1)
Doc 3	1 (1)	0	0	1 (1)	0	0.5 (1)	0.66 (2)	1	0.5 (1)

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y

Visualizaciones: Nubes de palabras

Se pueden ocupar
N-gramas y no sólo 1
palabra.



Visualizaciones: Nubes de palabras

Tambien, se pueden ordenar las palabras y agregar más elementos visuales.

Democractic Verbs

think⁹⁷ going⁷⁸ want⁷⁷
need⁷¹ did⁶⁶ get⁶¹ know⁶⁰
been⁵⁵ say⁵¹ had⁵¹ said⁴⁸ make⁴⁷
let⁴⁴ were⁴² go³⁹ believe³⁸ thank³⁵ take³²
look²⁹ does²⁸ got²⁸ talking²³ am²³ done²² put²² being²⁰
voted²⁰ come²⁰ made¹⁸ saying¹⁷ bring¹⁷ says¹⁵ doing¹⁵ support¹⁴
address¹⁴ move¹⁴ deal¹³ getting¹³ gonna¹³ talk¹³ stand¹² respond¹² coming¹²
trying¹² looking¹¹ having¹¹ hear¹¹ happen¹¹ help¹¹ heard¹¹

Republican Verbs


think¹⁴⁶ want¹⁴²
know¹³⁹ going¹²¹ said¹⁰⁸
need¹⁰⁶ thank⁹⁸ get⁹¹ did⁸⁸
say⁸¹ make⁸⁰ go⁷⁸ been⁷⁸ had⁶⁷ let⁵¹
put⁵⁰ does⁴⁹ take⁴⁸ done⁴⁵ were⁴⁵ tell⁴⁴ like⁴¹
talking³⁸ says³⁷ believe³⁵ got³⁴ give³⁴ look²⁹ come²⁸ see²⁷
respond²⁷ talk²⁶ bring²⁵ made²⁵ saying²⁴ am²³ use²² fight²¹ coming²⁰
went¹⁹ called¹⁸ being¹⁸ quote¹⁸ live¹⁸ agree¹⁷ mean¹⁷ ask¹⁷ doing¹⁷ work¹⁶
having¹⁶

Visualizaciones: *Bubble Cloud*

Se pueden mezclar con otros canales para entregar más información.


At the National Conventions, the Words They Used

A comparison of how often speakers at the two presidential nominating conventions used different words and phrases, based on an analysis of transcripts from the Federal News Service.



Visualizaciones: *WordWanderer*


Uso de la posición cómo *encoding* de alguna información



Visualizaciones: *How The Internet* Talks*

Cómo cambia la
búsqueda de ciertas
palabras en el tiempo.

(datos hasta septiembre
del 2017)



Visualizaciones: SHAP - *Text visualization*

Explicar por qué un modelo indica que este comentario es positivo en función de las palabras que contiene.

Azul: palabras negativas

Rosado: palabras positivas

```
[10]: # plot the first sentence's explanation
shap.plots.text(shap_values[3])
```



This is easily the most underrated film inn the Brooks cannon. Sure, its flawed. It does not give a realistic view of homelessness (unlike, say, how Citizen Kane gave a realistic view of lounge singers, or Titanic gave a realistic view of Italians YOU IDIOTS). Many of the jokes fall flat. But still, this film is very lovable in a way many comedies are not, and to pull that off in a story about some of the most traditionally reviled members of society is truly impressive. Its not The Fisher King, but its not crap, either. My only complaint is that Brooks should have cast someone else in the lead (I love Mel as a Director and Writer, not so much as a lead).



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvaldivieso@uc.cl) —
